RAG sistem nad Zakonom o bezbednosti saobraćaja na putevima

NBP/BP 2026 – Projekat br. 1b · Ognjen Aleksandar Jevtić, broj indeksa 74/2025 SI

1. Cilj projekta

Realizovan je RAG (Retrieval-Augmented Generation) sistem koji odgovara na pitanja o **Zakonu o bezbednosti saobraćaja na putevima Republike Srbije**. Sistem iz zakona pronalazi relevantne fragmente teksta pomoću vektorskog indeksa (FAISS). Na osnovu njih jezički model `openai/gpt-oss-120b` preko Groq platforme generiše odgovor.

Upoređena su dva pristupa (A i B), koji se razlikuju po načinu podele teksta i tipu vektorskog indeksa. Poređenje je urađeno na tri pitanja za koja je unapred utvrđeno u kom članu zakona se nalazi odgovor. Kao poboljšanje je dodat i pristup C, koji koristi dve tehnike sa predavanja: ponovno rangiranje (reranking) i hijerarhijsko dohvatanje.

2. Baza znanja

- **Izvor:** tekst zakona sa sajta paragraf.rs (`zakon_o_bezbednosti_saobracaja_na_putevima.html`), preuzet i parsiran skriptom `preuzmi_zakon.py` .
- Iz HTML-a se uzimaju pasusi sa klasom `clan` (naslov „Član N“) i `normal` (tekst). Naknadne izmene i dopune na kraju stranice (klasa `samostalni`) se ne uzimaju, jer imaju sopstvenu numeraciju članova, pa bi se brojevi članova duplirali.
- **Obim:** 362 člana, 3795 redova, oko 480 KB teksta na **srpskom jeziku**.

3. Arhitektura sistema

Korak	Skripta	Opis
1. Preuzimanje	`preuzmi_zakon.py`	HTML sa paragraf.rs → čist tekst `zakon.txt`
2. Fragmentacija	`podela.py`	Podela teksta na fragmente za pristupe A i B; svaki fragment pamti kojim članovima pripada
3. Indeksiranje	`indexi.py`	Embedding fragmenata (384 dimenzije, normalizovani vektori) i čuvanje FAISS indeksa na disk
4. Pretraga i generisanje	`preciznaEvaluacija.py` , `c_pristup.py`	Embedding pitanja → pretraga indeksa (top 5) → slanje fragmenata LLM-u uz uputstvo da odgovara isključivo na osnovu njih i navede član
5. Interaktivni režim	`preciznoPitaj.py`	Korisnik kuca proizvoljno pitanje i dobija odgovor sa izvorima i vremenom

Zajednički kod (pitanja, model, učitavanje indeksa, poziv LLM-a) izdvojen je u `unifer.py` .

4. Poređeni pristupi

	Fragmentacija	Br. fragmenata	Vektorski indeks
A	Fiksna dužina: 80 reči, preklapanje 20 reči. Ne vodi računa o granicama članova, pa jedan fragment može obuhvatiti kraj jednog i početak drugog člana.	1188	`IndexFlatL2`: tačna pretraga, poredi upit sa svakim vektorom (baseline)
B	Semantičke celine: po članovima i pasusima, do 500 znakova. Svaki fragment počinje naslovom „Član N“.	1214	`IndexHNSWFlat` (M = 32): graf najbližih suseda, približna i brža pretraga
C	Kao B, uz dva poboljšanja: **reranking** (FAISS vraća 20 kandidata, cross-encoder ih ponovo rangira i zadržava 5) i **hijerarhijsko dohvatanje** (LLM-u se šalju celi članovi kojima pripadaju pronađeni pasusi, najviše 3, do 4000 znakova po članu)	1214	`IndexHNSWFlat` + cross-encoder

Izbor embedding modela za srpski jezik

Korišćen je model `intfloat/multilingual-e5-small`. To je višejezični model treniran na tekstovima na oko 100 jezika, uključujući srpski (latinicu i ćirilicu) i srodne jezike. Daje vektore dimenzije 384, mali je (oko 470 MB) i radi lokalno, bez slanja podataka na spoljni servis. Model je treniran sa prefiksima, pa se tekstovi baze kodiraju sa `"passage: "`, a pitanja sa `"query: "`. Vektori su normalizovani, pa L2 rastojanje odgovara kosinusnoj sličnosti.

Za reranking u pristupu C korišćen je višejezični cross-encoder `cross-encoder/mmarco-mMiniLMv2-L12-H384-v1`, treniran na višejezičnom mMARCO skupu za rangiranje pasusa. mMARCO ne sadrži srpski, ali je osnovni model (multilingual MiniLM) treniran i na srpskom, pa se sposobnost rangiranja prenosi i na srpski tekst. Rezultati u odeljku 6 to potvrđuju.

5. Pitanja i mesto odgovora u izvoru

Pitanje 1: Koja je dozvoljena koncentracija alkohola u krvi vozača?

Odgovor: **Član 187, stav 3**

> *„Pod dejstvom alkohola je vozač, odnosno lice za koje se analizom odgovarajućeg uzorka krvi utvrdi sadržaj alkohola veći od 0,20 mg/ml …“*

Pitanje 2: Da li vozač sa probnom dozvolom sme da vozi noću?

Odgovor: **Član 182**, nabrajanje ograničenja za vozače sa probnom dozvolom

> *„Vozač koji ima probnu vozačku dozvolu ne sme da: … 3) upravlja motornim vozilom u periodu od 23,00 do 06,00 časova“*

Pitanje 3: Da li moram da imam zimske gume?

Odgovor: **Član 131, stav 2**

> *„Vozač je dužan da u saobraćaju na putu zimsku opremu poseduje i koristi na propisan način.“*

Ovo pitanje je namerno postavljeno jezikom korisnika („zimske gume“), dok zakon koristi pojam „zimska oprema“. Šta tačno spada u zimsku opremu, zakon prepušta podzakonskom aktu ministra (Član 131, stav 1).

6. Rezultati

6.1 Rang tačnog člana među prvih 5 fragmenata

Pitanje	A	B	C
1. Alkohol (Član 187)	1	1	1
2. Probna dozvola noću (Član 182)	nije u top 5	3	1
3. Zimske gume (Član 131)	nije u top 5	1	2
Pronađeno	**1 / 3**	**3 / 3**	**3 / 3**

6.2 Vremena

Pitanje	Embedding pitanja	Pretraga A	Pretraga B	Embedding + pretraga + reranking C
1. Alkohol	20,8 ms	0,048 ms	0,022 ms	1026,8 ms
2. Probna dozvola	18,3 ms	0,052 ms	0,025 ms	647,0 ms
3. Zimske gume	15,2 ms	0,049 ms	0,033 ms	1165,9 ms

Odgovor LLM-a	A	B	C
1. Alkohol	0,81 s	0,75 s	0,82 s
2. Probna dozvola	0,55 s	0,62 s	4,78 s*
3. Zimske gume	1,10 s	0,46 s	5,98 s*

Vreme pretrage A i B je prosek 1000 ponovljenih pretraga, jer jedna pretraga traje kraće nego što sat može pouzdano da izmeri. Embedding svih fragmenata pri izgradnji indeksa trajao je 33,8 s (A) i 29,5 s (B).
* Besplatni Groq nalog ograničava broj tokena po minutu. Pristup C šalje cele članove, dakle više teksta, pa biblioteka pri prekoračenju sama čeka i ponavlja zahtev. Kada se isti poziv izvrši pojedinačno, traje oko 1 s.

6.3 Odgovori LLM-a

Pitanje 1: Koja je dozvoljena koncentracija alkohola u krvi vozača?

A	Dozvoljena je najviše 0,20 mg/ml alkohola u krvi; veća koncentracija se smatra pod dejstvom alkohola. (član iz fragmenta [1]; definicija iz fragmenta [3]).
B	Dozvoljena koncentracija alkohola u krvi vozača je najviše 0,20 mg/ml; veća vrednost se smatra pod dejstvom alkohola. (Član 187, fragment [2])
C	Dozvoljena je najviše 0,20 mg/ml alkohola u krvi (do te granice vozač nije pod dejstvom alkohola). – Član 187.

Pitanje 2: Da li vozač sa probnom dozvolom sme da vozi noću?

A	Ne mogu naći odgovor na to pitanje u datim fragmentima zakona.
B	Ne, vozač sa probnom dozvolom ne sme da upravlja motornim vozilom u periodu od 23:00 do 06:00 časova (Član 182, stav 3).
C	Ne, vozač sa probnom vozačkom dozvolom ne sme da upravlja vozilom u periodu od 23:00 do 06:00 časova. (Član 182, stav 4)

Pitanje 3: Da li moram da imam zimske gume?

A	Ne mogu da nađem u datim fragmentima konkretno propisanu obavezu posedovanja zimskih guma. (Član 291 i članovi 131-132 spominju obaveznu upotrebu „zimske opreme“, ali ne navode izričito zimske gume.)
B	Da, prema Članu 131 zakona, vozač je dužan da u saobraćaju na putu poseduje i koristi zimsku opremu na propisan način. (Član 131)
C	Da, prema članu 131 vozač je dužan da u saobraćaju na putu zimsku opremu poseduje i koristi na propisan način. Takođe, po članu 291 policijski službenik može narediti upotrebu zimske opreme (uključujući zimske gume) i vozač mora postupiti po toj naredbi. (Čl. 131, Čl. 291)

7. Analiza

Pristup A nasuprot B

- **B je precizniji:** pronašao je tačan član za sva 3 pitanja, a A samo za prvo. Kod A fragment fiksne dužine često spaja delove dva ili tri člana (npr. „Član 73, Član 74, Član 75“). Vektor takvog fragmenta nosi mešavinu tema i slabije odgovara konkretnom pitanju. Kod B je jedan fragment jedna celina.
- **B omogućava citiranje izvora:** svaki fragment u B počinje naslovom „Član N“, pa LLM navodi tačan član. Kod A naslov člana često nije u fragmentu. Zato je u pitanju 1 odgovor A tačan, ali umesto broja člana navodi samo „član iz fragmenta [1]“.
- **Kad pretraga ne nađe pravi tekst, LLM ne izmišlja:** u pitanjima 2 i 3 pristup A nije doneo tačan član, a LLM je, prema uputstvu, odgovorio da odgovor ne može da nađe u datim fragmentima. U pitanju 3 je pomenuo članove 131–132 samo zato što se na njih poziva kaznena odredba (Član 333) koja je bila među fragmentima.
- **Brzina:** obe pretrage traju ispod 0,1 ms. HNSW (B) je oko 2 puta brži od Flat indeksa (A). Pri 1200 vektora razlika je praktično nebitna, ali kod Flat indeksa vreme raste linearno sa brojem vektora, dok kod HNSW raste znatno sporije, pa razlika postaje značajna na stotinama hiljada vektora. Ukupno vreme odgovora određuje LLM poziv (~0,5–1 s).
- Pristupi A i B se razlikuju i po fragmentaciji i po indeksu. Pošto je HNSW približna pretraga, ona ne može dati preciznije rezultate od tačne (Flat) pretrage nad istim vektorima. Zato se bolja preciznost pristupa B pripisuje fragmentaciji, a HNSW donosi brzinu.

Pristup C: reranking i hijerarhijsko dohvatanje

- **Reranking** je podigao tačan član na prvo mesto u pitanju 2 (B: rang 3 → C: rang 1). Embedding model kodira pitanje i fragment odvojeno, dok cross-encoder čita pitanje i fragment zajedno, pa preciznije procenjuje relevantnost. Zbog toga se primenjuje samo na 20 kandidata koje prethodno brzo izdvoji FAISS.
- **Hijerarhijsko dohvatanje** daje LLM-u ceo član umesto isečenog pasusa. U pitanju 3 tačan član je u C na drugom mestu (prvi je Član 291), ali je odgovor najpotpuniji: LLM je dobio cele Članove 131 i 291 i povezao obavezu posedovanja zimske opreme sa ovlašćenjem policije da naredi njenu upotrebu.

- **Cena:** reranking na procesoru traje 0,6–1,2 s po pitanju, što je hiljadama puta više od same FAISS pretrage, ali je istog reda veličine kao LLM poziv. Za sistem koji odgovara na pravna pitanja, tačniji odgovor uz sekundu dužeg čekanja je prihvatljiv kompromis. Na grafičkoj kartici reranking bi bio znatno brži (nije mereno).

LLM bez RAG-a

Isti model je, bez ikakvog konteksta, upitan „Da li vozač sme da vozi pod dejstvom alkohola?“. Odgovorio je opštim pregledom za više zemalja i za Srbiju naveo granice od 0,3 ‰ za mlade i nove vozače i 0,5 ‰ za ostale. To nije u skladu sa zakonom, koji propisuje granicu od 0,20 mg/ml (Član 187). Ovo je primer halucinacije: model iz znanja stečenog treniranjem daje uverljiv, ali netačan podatak. Sa RAG-om sva tri pristupa daju tačnu vrednost i pozivaju se na zakon.

Ograničenja

- Evaluacija je rađena na 3 pitanja, kako zahteva specifikacija. Za pouzdaniji zaključak o razlici između pristupa potreban je veći skup pitanja.
- Graf HNSW indeksa se pri svakoj izgradnji ne gradi uvek identično, a LLM ni uz `temperature=0` ne daje uvek isti tekst. Zato se rangovi i formulacije odgovora mogu neznatno razlikovati između pokretanja. Svi rezultati u ovom izveštaju potiču iz jednog pokretanja.
- Pitanje 3 pokazuje razliku između jezika korisnika („gume“) i jezika zakona („zimska oprema“). Odgovor zavisi od toga da li pronađeni tekst sadrži definiciju pojma.

8. Zaključak

Fragmentacija po semantičkim celinama (članovi i pasusi, pristup B) se pokazala znatno boljom od fragmentacije fiksne dužine (pristup A). B je pronašao tačan član za sva tri pitanja, a A samo za jedno, i LLM je uz B uvek mogao da navede tačan član kao izvor. Dodatna poboljšanja iz pristupa C, reranking cross-encoder modelom i hijerarhijsko dohvatanje celih članova, dodatno su poboljšala rangiranje i potpunost odgovora, po ceni od oko jedne sekunde dužeg odziva. Korišćenje RAG-a je ključno za tačnost: isti LLM bez konteksta daje netačnu zakonsku granicu alkohola.

9. Tehnologije

Jezik	Python 3.14
Vektorski indeks	FAISS (`faiss-cpu` 1.15.1): `IndexFlatL2` , `IndexHNSWFlat`
Embedding i reranking	`sentence-transformers` 6.2.0: `intfloat/multilingual-e5-small` , `cross-encoder/mmarco-mMiniLMv2-L12-H384-v1`
LLM	`openai/gpt-oss-120b` preko Groq API-ja (`groq` 1.7.0), `temperature=0`

Uputstvo za instalaciju i pokretanje nalazi se u fajlu `README.md` .